

Contents

调研结果与初步研究方案	1
流式语音对话中的端点检测与轮次预测	1
一、核心问题	1
二、相关工作与研究基础	1
三、主要研究问题	2
四、研究方案	3
五、场景标注与错误分析方案	3
六、实验设置	4
七、评价指标	4
八、数据集计划	5
九、数据划分原则	5
十、论文预期贡献	6
十一、整体研究主线	6
十二、来源记录	7

调研结果与初步研究方案

流式语音对话中的端点检测与轮次预测

本报告是本轮选题调研与初步方案，不代表本项目已经下载数据、实现模型或获得实验结果。

一、核心问题

本研究关注：

在严格流式约束下，系统如何利用已经到达的音频、增量语音识别结果和对话上下文，判断用户是否结束当前话轮，并在尽量不打断用户的前提下及时响应？

端点检测（end-of-turn detection, EOT）与语音活动检测（voice activity detection, VAD）并不相同。VAD 主要判断当前是否存在语音活动；EOT 还要判断当前停顿究竟是话轮结束、思考停顿、填充词、重复、自我修正，还是 backchannel/重叠语音中的短暂间隙。

理想的端点策略应同时满足：

1. **低误截断**：不在用户尚未说完时抢先响应；
2. **低响应延迟**：用户真正结束后尽快开始响应；
3. **严格因果**：时刻 t 的决策只能使用当前及过去已经到达的信息；
4. **可解释和可复现**：能够说明不同输入信号对延迟和误截断的影响。

本轮的研究定位不是重新提出一个“首次使用音频和文本”的模型，而是围绕统一的因果协议，比较固定阈值、声学模型、增量文本模型和融合模型在 latency 与 false-cutoff 之间的实际权衡。

二、相关工作与研究基础

2.1 理论基础：话轮不是简单的静音

Sacks、Schegloff 和 Jefferson 的会话分析工作讨论了话轮分配、转换相关位置和重叠等基本现象，为理解“何时可以换轮”提供了理论基础。S01

Schlangen 将话轮结束判断引入计算对话系统，推动研究从检测已经发生的暂停，转向结合句法、韵律等信息预测未来的结束点。S02

Schlangen 与 Skantze 的增量式对话处理框架进一步强调，系统不应等到完整 utterance 结束后才更新状态，而应在输入逐步到达的过程中持续处理。S03

2.2 技术路线的发展

阶段	代表工作	主要推进
会话轮次理论	Sacks et al. 1974	轮次、转换位置、重叠
反应式到预测式	Schlangen 2006	将暂停与句法、韵律结合
增量式处理	Schlangen & Skantze 2011	输入未完成时持续更新
连续轮次预测	Skantze 2017; Roddy et al. 2018	连续预测未来语音活动和轮次
EOT 与增量文本	Maier et al. 2017; Hara et al. 2019; Coman et al. 2019	比较声学、词、POS 和 partial
自监督与在线系统	Ekstedt & Skantze 2022; Chang et al. 2022	VAP、ASR 与结束判断联合建
融合与 benchmark	Uro et al. 2024; TurnBench; eot-bench	比较 audio/text/fusion，规范

2.3 代表性工作的层次判断

- **理论或框架基础：** S01、S02、S03 主要回答话轮为何需要预测、增量处理为何重要；
- **任务代表性工作：** Maier、Skantze、Roddy、Hara 和 Coman 直接推进了 EOT、连续轮次预测或增量文本决策；
- **现代技术路线：** Ekstedt、Chang 和 Uro 代表自监督预测、在线 ASR 和 audio-text 融合；
- **资源与评价工作：** TurnBench 和 eot-bench 的核心价值是统一数据格式、因果输入和交互指标，而不是单纯追求论文引用量。

这些工作已经覆盖声学特征、词特征、TRP、VAP、ASR 融合和公开 benchmark。因此，“把音频和文本拼接起来”不能直接作为创新点。

三、主要研究问题

3.1 严格流式条件下的主问题

在相同的 false-cutoff 预算下，加入声学特征和增量文本信息，能否相比固定静音阈值降低 endpoint latency?

这里需要明确：

- 模型不能访问未来音频、完整参考转写或未来标签；
- partial transcript 必须记录真实到达时间和 ASR 延迟；
- “可以结束”与“系统应该立刻接话”需要区分；
- EOT、TRP、terminality、turn-shift 和 interruption 不能未经说明地视为同一个标签。

3.2 具体子问题

1. 停顿时长、能量、F0、语速和历史语音活动等声学信息，能否减少思考停顿造成的误截断？
2. partial transcript 在什么情况下能提供比纯声学信号更早的结束证据？
3. 增量文本的收益是否会被 ASR 延迟、识别错误和文本不稳定抵消？
4. 思考停顿、填充词、重复、自我修正、未完成句、backchannel 和重叠语音是否需要不同策略？
5. 人机对话、人际对话、不同语言 and 不同录音条件之间，端点策略是否稳定？

3.3 当前认为最值得调查的不足

- 不同论文对“结束点”的定义、容忍窗口和 latency 起点并不完全一致；
- 使用完整转写或忽略 ASR 到达延迟，可能高估 audio-text 融合的效果；
- 单一 accuracy/F1 无法体现“更快响应”和“更少打断”的冲突；
- 总体平均分掩盖了不同停顿类型的错误机制；
- 现有数据、标签和评价协议差异较大，论文结果不能直接横向排名。

四、研究方案

整体模型尽量保持简单，先建立可核验的比较闭环：

音频流 → 因果声学表示 →

→ EOT/端点决策 → HOLD 或 SHIFT

增量 ASR 文本 → 文本表示 →

研究分为两个阶段。

阶段一：定义任务并建立基线

首先固定任务定义、可见信息和评分协议，不急于训练复杂模型。依次建立：

1. 固定静音阈值；
2. RMS/能量 VAD；
3. 轻量因果声学模型；
4. 增量文本模型；
5. 音频与增量文本融合模型。

每个模型都要输出可回放的端点时间，并记录输入时间、决策时间、ASR 文本到达时间和最终标签。

阶段二：受控比较与错误分析

在同一数据划分、标签和因果模拟条件下改变输入信号，而尽量不同时改变模型结构。重点比较：

- 声学信息相对静音阈值的收益；
- 增量文本相对纯声学信息的边际收益；
- ASR 延迟和文本错误带来的代价；
- 不同停顿类型下 latency 和 false-cutoff 的变化；
- 不同语言、场景和说话人划分下的泛化能力。

五、场景标注与错误分析方案

本方向的关键不是一开始收集大量主观偏好，而是先把端点决策中的困难情况拆开。若数据集已有事件标签，则优先使用原始标注；若需要补充人工检查，采用小规模、针对性抽样。

5.1 建议的错误类别

- 思考停顿；
- 填充词之后的停顿；
- 重复或自我修正；
- 句法尚未完成的停顿；
- 句法完成但语义仍未结束；

- backchannel;
- overlap 或 interruption;
- 噪声、回声和 channel bleed。

5.2 样本选择原则

不建议完全随机地检查样本，而应优先选择：

- 模型与固定阈值判断不一致的样本；
- 不同模态模型判断不一致的样本；
- latency 很低但发生 false-cutoff 的样本；
- latency 很高但最终判断正确的样本；
- TurnBench 或 eot-bench 中具有明确 hesitation/hold 标记的样本。

这些样本可形成一个小规模的 **Pause Conflict Set**，用于检查模型是否把“短暂安静”错误地当成“用户结束”。该集合是错误分析工具，不应在没有独立划分时直接作为正式测试集。

六、实验设置

Experiment 1: 固定阈值与因果声学基线

比较固定静音阈值、RMS/能量 VAD 和轻量因果声学模型，回答：声学历史是否能在相同 false-cutoff 预算下减少 endpoint latency？

Experiment 2: 增量文本的边际作用

固定声学部分，只加入在对应时刻已经到达的 partial transcript，比较声学模型和文本增强模型。必须记录 ASR 延迟，并设置无文本、低延迟文本和带实际延迟文本等条件。

Experiment 3: 融合与错误类型消融

比较 audio-only、text-only 和 audio-text fusion，并按停顿类型分析错误。目标不是证明融合一定更好，而是判断文本收益出现在哪些场景、付出了多少延迟代价。

Experiment 4: 跨场景和跨语言泛化

在说话人隔离、场景隔离或语言隔离的条件下测试模型。重点观察分布外性能下降，而不是只报告训练分布内的最高分。

Experiment 5: 策略层而非单一分类分数

对模型输出进行 threshold、action delay 和 timeout 的策略扫描，绘制 latency-false-cutoff Pareto frontier。这样可以区分“模型打分能力”和“系统策略选择”两个因素。

七、评价指标

主要指标包括：

1. **EOT precision、recall 和 F1**：用于描述基本识别能力；
2. **false-positive/cutoff rate**：衡量在中间停顿处过早响应的比例；

3. **median endpoint latency**: 衡量真正结束后系统等待多久;
4. **固定误截断预算下的 latency**: 例如 cutoff 预算为 5% 或 10% 时的延迟;
5. **固定 latency 预算下的 false-cutoff**: 观察系统在响应速度受限时的安全性;
6. **分场景错误率**: 分别统计 hesitation、backchannel、overlap、未完成句等场景;
7. **稳定性**: 报告多个随机种子、说话人划分和语言/场景划分下的结果。

核心结果不应只呈现最高 F1，而应至少包含：

false-cutoff rate <-> endpoint latency

TurnBench 官方页面和 eot-bench 官方仓库都将这一权衡作为核心评价对象：等待过久会产生 dead air，过早触发则会打断用户。因此，Pareto frontier 比单个阈值下的分类分数更适合描述交互质量。[S13](#) [S15](#)

八、数据集计划

8.1 TurnBench：首选候选基准

TurnBench 官方页面介绍了 30 小时双通道双人语音、154 段对话、106 位演员和 6 类对话类型；每段对话由三名标注者处理，并提供 EOT 与 interruption 评价轨道。官方评价要求模型输出因果时间点，同时报告 recall、false-positive rate 和 median latency。[S13](#)

该资源与本研究的问题最直接对应，适合作为第一候选基准。但在正式使用前，仍需单独核验数据访问条件、数据许可证、代码许可证、训练/开发/测试划分和提交格式。公开代码不等于数据可以无条件使用。

8.2 eot-bench：补充候选资源

eot-bench 官方仓库提供 14 种语言的人机对话用户话轮，带有音频和文本上下文，并将每个至少 100 ms 的停顿区分为最终结束停顿和中间 hesitation。其评价围绕实际的 latency 与 false-cutoff 权衡展开。[S15](#)

它适合研究多语言和真实人机任务场景，但与 TurnBench 的说话人关系、标签、数据来源和评价协议不同，不能直接混合两个 benchmark 的绝对分数。

8.3 Switchboard 的位置

Switchboard 可作为自然电话对话的补充资源，用于观察历史轮次统计或做泛化参考。但如果从词对齐重新推导 EOT 标签，需要另行说明标签质量、结束点定义和评价协议，因此当前不把它作为未经核验的主 benchmark。

九、数据划分原则

数据划分必须先于窗口切分、停顿抽取和 triplet/样本构造：

原始对话/说话人 -> Train / Validation / Test -> 时间窗口与端点样本

必须遵守：

1. 同一对话或同一说话人的高度相似片段不能同时出现在训练和测试中；
2. 测试时只能使用决策时刻之前已经到达的音频和文本；
3. 若加入 ASR 文本，应保存文本的生成时间，而不是只保存最终转写；
4. 阈值和 action delay 只在验证集调节，测试集只做一次最终评估；

5. 不同 benchmark 的绝对分数不直接合并;
6. 若进行跨语言、跨场景或跨数据集测试, 应明确写出训练域和测试域;
7. 外部 benchmark 的榜单数字只能作为背景证据, 不能写成本项目实验结果。

十、论文预期贡献

如果后续实验能够成立, 本研究可能形成以下贡献:

1. 明确一套严格因果的流式端点检测比较协议, 记录音频、增量文本和 ASR 延迟的可见性;
2. 在同一评价条件下比较静音阈值、声学模型、增量文本模型和融合模型;
3. 在固定 false-cutoff 预算下报告 latency, 并用 Pareto frontier 表达交互权衡;
4. 对思考停顿、未完成句、backchannel、重叠语音和噪声等错误类型进行细分分析;
5. 讨论增量文本收益是否足以抵消 ASR 延迟和文本不稳定性。

这些属于“统一协议、受控比较和错误分析型”贡献, 不表述为首次提出 EOT、首次使用 audio-text fusion 或首次解决轮次预测。

十一、整体研究主线

整个研究可以概括为:

Define -> Diagnose -> Compare -> Generalize

Define

先定义 EOT、VAD、TRP、turn-shift、interruption 和 terminality 的关系, 明确数据、标签和因果可见信息。

Diagnose

建立固定阈值和轻量声学基线, 分析模型在不同停顿类型中的错误, 确认问题主要来自静音判定、声学线索不足还是标签协议不一致。

Compare

在同一数据和评价协议下加入增量文本与融合模型, 用 latency、false-cutoff 和场景错误率衡量边际收益, 而不是只比较 F1。

Generalize

在说话人、场景、语言或数据集发生变化时验证稳定性, 并报告性能下降和不确定性。

最终希望回答:

在不读取未来信息的严格流式条件下, 声学历史和增量文本是否能在可接受的误截断预算内减少系统等待时间? 如果能, 收益来自哪些场景, 是否足以抵消 ASR 和系统复杂度带来的代价?

当前阶段边界

本轮只完成文献、公开 benchmark 和研究方案的初步调研，不下载数据、不运行 baseline、不提交本项目实验结果。下一步应先全文核对核心论文的数据划分、标签生成、latency 定义和许可证，再决定是否进入复现阶段。

十二、来源记录

以下来源均为可直接访问的论文官方页面、官方 benchmark 页面或官方仓库；本报告不依赖仓库内其他 Markdown 文件作为正文证据。

编号	来源	用途
S01	Sacks, Schegloff & Jefferson, 1974	话轮组织、转换位置和重叠的理论基础
S02	Schlangen, 2006	从反应式暂停检测转向预测式处理
S03	Schlangen & Skantze, 2011	增量式对话处理框架
S04	Skantze, 2021/2020 DOI review	轮次预测、EOT、backchannel 和 interruption 综述入口
S05	Skantze, 2017	连续神经轮次预测
S06	Maier, Hough & Schlangen, 2017	live EOT、声学/词特征和 latency/cut-in
S07	Roddy, Skantze & Harte, 2018	声学、词和 POS 特征的连续预测
S08	Hara et al., 2019	TRP 与是否接话的区分
S09	Coman et al., 2019	token-by-token 增量文本决策
S10	Ekstedt & Skantze, 2022	Voice Activity Projection 与自监督轮次事件预测
S11	Chang et al., 2022	ASR、思考停顿和结束判断的在线建模
S12	Uro et al., 2024	audio/text/fusion 及稳定性分析
S13	TurnBench 官方页面	双通道对话、EOT/interruption、recall/FPR/latency
S14	TurnBench 论文入口	benchmark 协议和数据说明
S15	LiveKit eot-bench 官方仓库	多语言 EOT、causal silence decision 和 Pareto 评价